

• تکلیف یادگیری عمیق ۳ – پاسخ سؤال ۱

• (الف) محدودیت‌های Transfer Learning

• چرا مدل‌های pretrained روی ImageNet ممکن است در

حوزه تصویربرداری پزشکی عملکرد ضعیفی داشته باشند:

• راهکارهای بهبود:

• (ب) لایه Fully Connected در برابر Convolutional

• کارایی پارامترها (Parameter Efficiency)

• ریسک overfitting

• بایاس استقرایی (Inductive Bias)

• قابلیت تفسیر

• مثال‌ها

• (پ) مقابله با Overfitting در شبکه‌های عمیق

• تکنیک ۱: Dropout

• تکنیک ۲: Data Augmentation

• (ت) شبکه‌های Siamese

• (ث) توابع Activation

بسم الله الرحمن الرحيم

نام: سینا سپهوند

شماره دانشجویی: ۴۰۳۲۹۰۴۰۰۱

تکلیف یادگیری عمیق ۳ – پاسخ سؤال ۱

(الف) محدودیت‌های Transfer Learning

چرا مدل‌های pretrained روی ImageNet ممکن است در حوزه تصویربرداری پزشکی عملکرد ضعیفی داشته باشند:

۱. شکاف دامنه (Domain Gap)

- ImageNet شامل تصاویر طبیعی (حيوانات، اشیاء، مناظر) است، در حالی که تصاویر پزشکی ویژگی‌های بصری کاملاً متفاوتی دارند.
- تصاویر پزشکی اغلب از modality های متفاوت (مانند X-ray، MRI، CT، histology) با توزیع شدت و نویز خاص تولید می‌شوند.
- فضای رنگی متفاوت است: ImageNet مبتنی بر RGB است، در حالی که تصاویر پزشکی معمولاً grayscale یا دارای mapping رنگی تخصصی هستند.

۲. عدم انطباق در بازنمایی ویژگی‌ها (Feature Representation Mismatch)

- ویژگی‌های سطح پایین یادگرفته‌شده (مانند edges و textures) در تصاویر طبیعی الزاماً برای پزشکی کاربردی نیستند.
- ویژگی‌های سطح بالای semantic (مثل گربه، ماشین، درخت) کاملاً بی‌ارتباط با تشخیص پزشکی‌اند.
- تصاویر پزشکی نیازمند الگوهای domain-specific هستند (ساختارهای آناتومیک، نشانه‌های پاتولوژیک).

۳. تفاوت در آمار تصاویر (Image Statistics)

- توزیع شدت و الگوهای contrast متفاوت است.
- پروتکل‌های اخذ تصویر پزشکی استانداردسازی شده و با عکاسی طبیعی متفاوت‌اند.
- وضوح فضایی و نسبت ابعاد نیز می‌تواند تفاوت داشته باشد.

راهکارهای بهبود:

۱. Pretraining دامنه-ویژه

- استفاده از مدل‌های pretrained روی دیتاست‌های پزشکی (مثل CheXNet برای X-ray قفسه سینه).
- در صورت وجود داده کافی، ایجاد foundation modelهای پزشکی.

۲. Fine-tuning تدریجی (Progressive Fine-tuning)

- ابتدا ثابت نگه‌داشتن لایه‌های اولیه و سپس آزاد کردن تدریجی لایه‌های عمیق‌تر.
- استفاده از learning rate کمتر برای لایه‌های pretrained و بیشتر برای لایه‌های جدید.
- بهره‌گیری از استراتژی unfreezing مرحله‌ای.

۳. Domain Adaptation و Data Augmentation

- به کارگیری augmentationهای مرتبط با پزشکی (چرخش، تغییر شدت، شبیه‌سازی نویز).
- استفاده از تکنیک‌های domain adaptation (مثل adversarial training).
- به کارگیری cyclic learning rate و regularization مناسب.

(ب) لایه Fully Connected در برابر Convolutional

کارایی پارامترها (Parameter Efficiency)

- **Convolutional Layers**: اشتراک پارامترها در ابعاد فضایی → کاهش شدید تعداد پارامترها.
- **Fully Connected Layers**: هر ورودی به هر خروجی وزن مستقل دارد → پارامترها به شدت زیاد.

ریسک overfitting

- **Convolutional Layers**: به دلیل اشتراک وزن و translation invariance ریسک پایین‌تر.

- **Fully Connected Layers**: پارامتر زیاد → ریسک overfitting بالا → نیازمند regularization.

بایاس استقرایی (Inductive Bias)

- **Convolutional Layers**: فرض محلی بودن پیکسل‌ها و translation invariance → یادگیری سلسله‌مراتبی ویژگی‌ها.
- **Fully Connected Layers**: فاقد فرض ساختاری → توانایی یادگیری نگاشت دلخواه اما نیازمند داده زیاد.

قابلیت تفسیر

- **Convolutional Layers**: فیلترها قابل progression → visualization از edges تا الگوهای پیچیده.
- **Fully Connected Layers**: ماتریس وزن‌ها تفسیر دشوار → نیازمند تکنیک‌های attribution.

مثال‌ها

- **Convolutional** مؤثرتر: Classification تصاویر (به دلیل ساختار مکانی و translation invariance).
- **Fully Connected** مؤثرتر: پردازش داده‌های جدولی (روابط غیرمکانی بین ویژگی‌ها).

تکنیک ۱: Dropout

- مفهوم: غیرفعال سازی تصادفی درصدی از نورون ها در training.
- موارد کاربرد: لایه های fully connected بزرگ، دیتاست کوچک.
- محدودیت ها: کندی همگرایی، عدم کارایی در نرخ های بالا، تداخل با batch normalization.

تکنیک ۲: Data Augmentation

- مفهوم: افزایش مصنوعی اندازه دیتاست با تبدیلاتی مثل چرخش، نویز.
- موارد کاربرد: وظایف vision با داده کم، نیاز به robust بودن.
- محدودیت ها: هزینه محاسباتی، ریسک تغییر برچسب، امکان وارد کردن bias ناخواسته.

(ت) شبکه های Siamese

تعریف: معماری شامل دو زیرشبکه یکسان با اشتراک وزن که ورودی های مختلف را در فضای embedding مشترک مقایسه می کنند.

مزایا در وظایف Verification:

۱. یادگیری مستقیم شباهت: مناسب برای وظایف same/different.
۲. توانایی Few-shot learning: بدون نیاز به retraining برای کلاس های جدید.
۳. پایداری در عدم توازن کلاسی: تمرکز روی مقایسه زوج ها به جای توزیع کلاس.

اجزای اصلی:

۱. Shared Feature Extractor

۲. **Distance/Similarity Metric** (مانند cosine similarity یا Euclidean

(distance

۳. **Loss Function** (contrastive loss, triplet loss, یا binary cross-

(entropy

Activation (ث) توابع

:ReLU

- کاربرد در معماری‌های مدرن (CNN, ResNet, Transformer).
- مزایا: کارایی محاسباتی، حل مشکل vanishing gradient.
- معایب: مشکل dead neuron، عدم صفر-مرکزی.

:Sigmoid

- مناسب برای output باینری.
- مزایا: bounded به $[0, 1]$.
- معایب: vanishing gradient شدید، saturation.

:Tanh

- مناسب در RNN/LSTM و جاهایی که خروجی zero-centered مهم است.
- مزایا: خروجی در بازه $[-1, 1]$ ، بهبود جریان گرادیان.
- کاربرد در hidden state و بعضی normalization scenarios.